固定候选表示下的信息交换与答案选择

DASE7506 Advanced Machine Learning Methods · MP2

3036709042 Wang Ziyue

摘要

每道数学题提供四个固定候选解答，选择器需要选中最终数值正确的一项。本实验围绕“候选是否应该交换信息，交换什么、怎样交换、在哪个阶段交换”展开。在给定 1024 维表示上，初始独立打分、平均上下文和注意力的五种子验证准确率分别为 90.226%、91.504%和 91.905%，支持跨候选上下文的价值，但注意力相对简单池化的优势不确定。改变训练分配后，注意力与独立模型的差距缩小，说明结构收益依赖学习条件。显式答案共识改变了选择偏好，并显著损害错误共识子组；头数、残差、答案组池化及注入位置的对照尚未确定稳定最优的交换方式或阶段。局部算术矛盾校正仅带来小幅增量，关系证据探针未达到建模门槛。测试前选定的矛盾校正方案 V 得到 374/467，即 80.086%；六套冻结方案中，固定回退方案观察最高，为 82.013%。这些结果说明上下文读取具有开发价值，同时需要区分交换机制、票数先验与新增证据，并保留重复验证开发和测试筛选差异的限制。

1 任务与研究问题

1.1 任务定义

课程提供题干、四段候选文本及形状为[N, 4, 1024]的固定表示。方法输出一个 0 至 3 的候选索引，官方评分器检查该候选解析后的最终数值；同题可有多个正确候选，题库保证至少一个正确候选。最终数值正确不等于推理步骤全部正确。预测不得读取参考答案、生成新候选或调用外部模型。[1]

表 1　数据规模与选择难度

划分	总题数	单有效答案组	至少两个有效答案组
训练	4755	2641	2114
验证	798	443	355
测试	467	0	467

“单有效答案组”允许部分候选无法解析；在至少一个候选正确的保证下，任取有效候选即可得分。它不同于“四候选全对”，后者在训练和验证中分别为 2242 题和 379 题。含正确与错误候选的混合题分别为 2513 题和 419 题，也不同于表 1 的分歧题。

1.2 主线与预期

官方问题“Should a solution be judged on its own?”启发了本实验的主线：在固定候选表示下，候选之间是否应该交换信息；交换什么、怎样交换、在哪个阶段交换，才能改善最终答案选择？工作假设是其他候选可以提供相对判断依据；但如果交换的是共同错误形成的共识，交互也可能强化错误。各轮实验据前期发现逐步展开，下文区分受控比较与后续诊断，不将整条研究路线追认为一次性预注册设计。

2 信息通路与实验协议

2.1 固定表示与交换的操作定义

固定的是课程提供的候选向量，而不是下游网络参数。逐维标准化只拟合训练输入；编码器、注意力和读出从随机初始化学习。独立模型对各候选共享同一函数；表示交互则允许某候选的分数依赖同题其他候选。初始模型不使用候选位置编码。[2]

表 2　信息通路与需要区分的改动

层面	代表方法	比较含义
独立评分	线性与独立 MLP	推理时各候选单独打分
表示层交换	Pool 与注意力	读取候选均值或学习的加权上下文
显式答案结构	共识特征与答案组	传递支持数或按数值相等建立分组
监督中的比较	Pairwise 与 set-mass	损失耦合候选，推理未必存在交互
决策层汇总	回退与专家选择	根据已有分数和答案结构改变选择
候选自身证据	格式与算术校正	新增局部证据，校正项本身不传递候选消息

Pool 将自身表示与四候选平均表示拼接后评分。注意力 A 使用 128 维编码、一层四头自注意力、残差与 LayerNorm、256 维 FFN 及 64 维评分头。S2 保持这些模块，改变 FFN 残差与归一化的位置。后期 P 表示仅解析有效性，C 表示解析加共识；初始报告中用 P 指池化，本文统一写 Pool 以免混淆。

I-C 的向量分支虽然独立，显式共识仍来自整组候选，因此它不是完全独立的信息条件。题目词袋、解析、风格和算术特征都扩展了纯向量模型的可见信息；它们符合任务输入权限，但不能把其收益直接归于交互架构。不同种子的集成汇总的是模型预测，也不等于新增一层候选间交换。

2.2 训练与评价约定

主要比较使用种子 17、29、43、71、101，保留多正确候选标签。常用设置为 AdamW、batch256、dropout0.1、weight decay0.001 和梯度裁剪 1。早期每组搜索两档学习率并按验证集早停；交互阶段实验完整训练 60 轮，再选验证最佳检查点；后期因子实验多固定 20 轮取末轮。跨协议历史最好分不作为单一变量的增益分母。

正式准确率来自未修改的独立评分器。单模型均值与五成员集成分别报告；后者是一个固定预测器。配对区间按题目重采样，单模型比较先平均同题五种子的正确性，不把 5×798 个结果当作独立样本。区间条件于已训练和已选择的模型，未覆盖反复开发的选择偏差，也未作多重比较校正。

训练 OOF 按整题五折划分，四候选不跨折，标准化只拟合其余四折，基础模型不利用留出折选择检查点。阈值和小校正器只在训练 OOF 上拟合；校正器拟合后的同批 OOF 成绩仍是拟合内诊断，不是该校正器自身的无偏验证。[5,10,12]

3 候选是否应该交换信息

3.1 初始交互收益及容量控制

表 3　初始结构比较　五种子验证结果[2]

模型	参数量	准确率均值±SD
线性读出	1025	90.075% ± 0.241
独立 MLP	139521	90.226% ± 0.266
平均上下文 Pool	147713	91.504% ± 0.348
候选注意力 A	272001	91.905% ± 0.514
近容量独立 MLP	271489	90.476% ± 0.396
仅自身注意力	272001	90.075% ± 0.429

Pool 相对独立模型提高 1.278 个百分点，95%描述区间为[0.326, 2.306]；A 提高 1.679 个百分点，区间为[0.677, 2.732]。近容量独立网络没有追上 A；限制注意力只读自身后，表现也较低。这些控制支持跨候选读取的作用，而不只是存储参数增加。仅自身注意力的单键 softmax 会使 Q/K 匹配退化，所以它仍不是有效容量完全相同的控制。

A 相对 Pool 仅提高 0.401 个百分点，区间[−0.351, 1.178]跨零。因此较可靠的结论是上下文有用，而不是复杂注意力已经稳定胜过均值汇总。固定首候选和答案多数投票分别为 78.195%和 86.216%；投票额外读取答案文本，不能作为纯向量模型的同信息基线。

3.2 训练分配改变结构差距

表 4　训练目标与结构联合比较　五种子均值[3]

训练目标	独立 MLP	注意力 A	A 减独立 pp
全部题 BCE	90.226%	91.905%	+1.679
混合题 BCE	91.303%	91.429%	+0.125
混合题成对排序	91.028%	91.203%	+0.175
正确集合概率质量	90.827%	90.652%	−0.175

混合题 BCE 使独立模型提高 1.078 个百分点，区间[0.150, 2.055]；同条件 A 与独立模型仅差 0.125 个百分点，区间跨零。这一变化同时包含训练题分布、标签比例和困难题重复曝光，不能仅归因于去掉无用梯度。成对排序及集合目标相对匹配混合 BCE 也未得到可靠收益。

容量和正则化实验中，缩小独立模型略有改善但区间跨零；缩小注意力或增加 dropout 未提高其均值。训练与验证差距缩小不等于选择能力改善。[3] 综合而言，初始设置支持交换上下文，但收益依赖学习协议，尚不能断言任意目标下都需要交互。

4 候选之间应交换什么信息

4.1 固定表示上下文与显式答案共识

C 包含六项输入：解析有效性、当前答案支持数、不同有效答案数、是否处于最大答案组、最高票是否并列、前两大组票差。它刻画数值答案的重复结构，没有显式对齐候选的条件、实体或计算步骤。为检查共识能否替代表示交互，使用 I、Pool、S2 三种结构与 P/C 两种信息条件交叉，统一 20 轮和最终解析过滤。[7]

表 5　结构与共识因子实验　单模型为五种子均值

配置	完整验证	错误最高票 60 题	五成员正确数/798
I-P	91.003%	50.000%	731
I-C	90.251%	12.333%	718
Pool-P	92.256%	60.333%	736
Pool-C	91.629%	28.333%	731
S2-P	91.855%	60.000%	735
S2-C	92.155%	36.333%	740

主要比较为 Δ=(S2-C−I-C)−(S2-P−I-P)，得到+1.053 个百分点，区间[−0.150, 2.281]。结果未确认共识与 S2 交互是稳定互补还是替代。正点估计部分来自 I 加入共识后下降，不能只凭差值之差声称所有结构都从共识受益。三个结构的整体 C−P 区间均跨零。

4.2 交换共识的代价

错误最高票指唯一最大频次的有效答案是错的，不必超过全部四候选的一半。验证共有 60 道此类题，均属于 117 道唯一正确候选题，两个子组不能相加。加入 C 后，I、Pool、S2 在这 60 题上的五种子均值分别下降 37.667、32.000、23.667 个百分点，描述区间均低于零。S2 比 I 更能抵抗共识风险，不意味着 S2-C 比自身 P 版本更擅长反对错误多数。

早期融合中，普通 S2 五成员总体 735/798，共识模型 740/798；错误最高票却由 37/60 降至 24/60，唯一正确候选由 75/117 降至 63/117。整体提高与少数正确答案受损同时存在。风格对照在解析之上变化−0.075 个百分点、在共识之上+0.025 个百分点，均不确定，未支持把收益归于表面形式。[5]

4.3 训练关注未解除这一取舍

重加权用 K 匹配正确候选数量和正负标签权重总量，再用 H 特别提高错误共识题权重。主要比较 C-H 对 C-K 在错误共识上为−1.667 个百分点，区间[−4.333, 0.667]。C-H 相对均匀训练只提高 0.333 个百分点，未达到预设实用目标；训练准确率却从 83.106%升至 88.937%。[8]

这说明当前预算下更多训练关注未转化为相应泛化。现有证据识别了答案统计的风险，但仍未直接确定注意力从向量中读取了什么语义内容。上下文收益、票数依赖和理解题意是三个不同层次的结论。

5 候选之间应怎样交换信息

5.1 简单汇总与选择性读取

Pool 已在初始设置取得主要增益；后期 P 条件下，其五种子均值 92.256%还高于 S2-P 的 91.855%，但差值区间跨零。不同协议不能合成一个结构排行榜，现有证据也没有建立注意力的普遍优势。注意力权重和熵描述读取分布，不能单独证明模型使用了某个候选中的正确推理。

头数实验固定总宽度 128 及参数量，交叉比较 1/2/4/8 头与允许/排除自身。最佳两头排除自身为 92.005%，仅比原四头高 0.100 个百分点，区间[−0.351, 0.551]。排除自身只屏蔽 key/value 对角线，自身 query 和残差保留；改变头数也改变每头宽度。因此结果不支持“更多比较角度”或“只看其他候选”必然更优。[4]

5.2 从候选表示到答案组表示

答案组实验先以 CandMaxCE 隔离损失改变，再用 GroupCE 检验同答案候选的平均及逐维最大池化。六方案参数量相同，只训练 2114 道分歧题，固定 380 次更新；Size 提供支持数，NoSize 不提供。[9]

表 6　答案组读出与显式支持数　五成员结果

方案	NoSize 正确/798	Size 正确/798	NoSize 错误最高票/60
CandBCE	735	735	31
CandMaxCE	733	732	35
GroupCE	732	731	34

GroupCE_NoSize 相对匹配 CandMaxCE 的单模型均值提高 0.301 个百分点，区间[−0.376, 0.977]，种子方向不稳定；集成修复 8 题、损害 9 题。反多数表现的改善首先出现在 BCE 改为组 CE 时，同时总体少对 2 题；不能将它归给组表示。NoSize 只消融显式支持数，组成员关系与池化仍可能携带隐含数量信息。

新组模型还改变了历史 S2-C 的读出、训练范围、无效候选监督及集成概率口径，故不能用 732 对历史 740 直接估计池化的净效果。结论限于当前池化和预算，不能推出固定向量中已不存在可用信息。

5.3 决策层交换与计算收益

Pool-P 与 S2-C 在 38 道验证题上输出不同数值，分别有 16 和 20 题独有正确；已知标签后任选正确方法的 oracle 为 756/798。等权、OOF 选权重、8 特征和 4 特征门控均为 740，均修复 5 题、损害 5 题，却需约 8.12MiB 资产，对比 S2-C 的 5.25MiB。四种方法同分不代表预测相同。[10]

普通 S2 由固定 seed17 的 724 题提高到五成员 735 题；十五成员均值融合仅 732 题，资产增至 13.347MiB。前一增益也受固定种子表现影响。[5] 方法间互补确实存在，但当前分差、一致率和票数没有可靠兑现该上界。增加计算并不自动弥补交换内容的不足。

最终排除解析无效候选使普通 S2 从 735 提高到 737；在同过滤基线上再加冻结回退达到 740，修复 5 题、损害 2 题。净增 3 题的区间仍跨零，原 735 到 740 不能全部归因于置信度识别。过滤本身来自评分约束，不代表理解推理。[6]

6 信息应该在哪个阶段交换

6.1 网络内加工与交互的先后

令 A 表示带残差及归一化的注意力步骤，P 表示逐候选 FFN 残差，N 表示其 LayerNorm，完整逐候选块 F=N(P)。保持编码器和评分头，S0—S2 参数相同；S3—S5 增加第二个独立块。每组完整训练 60 轮，主比较使用本轮 S0 及各自验证最佳检查点。[4]

表 7　交互位置对照　五种子准确率

布局	模块顺序	参数量	验证均值
S0	A → F1	272001	91.905%
S1	F1 → A	272001	91.805%
S2	P1 → A → N1	272001	92.306%
S3	F1 → F2 → A	338177	91.729%
S4	F1 → A → F2	338177	91.930%
S5	A → F1 → F2	338177	91.880%

S2 相对 S0 提高 0.401 个百分点，五种子同向，但区间[−0.075, 0.877]跨零。S1 整块前置没有相同收益；S1 对 S2 的区间同样跨零，不能确认归一化机制。S4 也没有可靠胜过同容量 S3/S5。因而“先进行部分非线性加工再交互”是有待确认的信号，不能概括成交互越晚越好。

6.2 共识在交互前还是交互后进入

另一组将 All/D 训练范围、P/C 特征与 Early/Late 注入组成 2×2×2 实验。Early 在编码后、FFN 与注意力前加特征投影；Late 在交互与归一化后加同样投影。八组初始函数及预算匹配，均固定 380 次更新。[8]

表 8　早期注入的预设比较　完整验证差值

比较	差值 pp	95%描述区间
分歧题训练 D 减 All	−0.251	[−0.821, 0.332]
C 条件 Early 减 Late	−0.238	[−0.877, 0.376]
C 与 P 的早期效应之差	−0.125	[−0.827, 0.551]

三项均未提供明确正向证据。Early 同时改变特征影响 FFN、注意力及归一化的路径，并未区分仅 Q/K 或仅 V。两位置都使用加法投影，也不能用历史拼接式 S2-C 作为 Late 基线。

6.3 先独立判断再修正

两阶段残差实验先训练独立模型，再学习跨候选分数修正。冻结版本为 90.326%，对独立模型仅+0.100 个百分点，对共同训练 A 为−1.579 个百分点。该方案冻结了候选编码器，且二阶段没有使用 OOF 独立分数，限制其外推。[4] 网络顺序、特征注入与训练先后是三种不同“阶段”；现有结果尚未确定一个统一最优时机。

7 信息交换的失败边界与证据扩展

7.1 共同行为不等于可靠判断

对 Pool-P 与 S2-C 共同失败的 42 道验证题，阅读题干、所选错误候选及全部官方数值正确候选，共 95 份必要候选全文。40 题两代表选中同一错误数值，38 题只有一个正确候选。每题给一个主类别，次要问题另记；审阅由 AI 辅助完成，没有独立第二位评审，也不代表全题库错误分布。[11]

表 9　42 题的主要错误类型

主类别	题数	主类别	题数
数量实体或累计范围	13	局部算术等式	5
题意与数量关系绑定	8	单位换算	1
遗漏改写或添加条件	8	输出与解析错位	2
未回答所求量	4	题面与参考疑点	1

数量、关系、条件及目标四类合计 33 题，常需要将题目含义绑定到计算，而不仅是复核等式。另有 6 题的唯一官方正确候选存在明显过程错误，却落到正确数值。因此发现过程瑕疵不能直接硬淘汰候选；这些类别也不是模型内部失败机制的因果证明。

7.2 新增证据与交换机制分开归因

冻结 S2-C，在训练 OOF 上学习很小的候选分数残差。第一轮格式校正为 740，算术及合并均 741，修复 3 题、损害 2 题；多数变化含可检查等式数量的代理影响。后续固定提取器，分别重新拟合数量 N、矛盾 V 和合并 NV；移除错误比例项以避免分母引入数量，历史完整四维 H 只作回放。[12,13]

表 10　算术证据消融　基线 B 为 S2-C 五成员

方案	正确/798	修复/损害	相对 B 差值 pp	95%描述区间
B	740	0/0	0.000	[0.000, 0.000]
N	739	2/3	−0.125	[−0.627, 0.376]
V	742	2/0	+0.251	[0.000, 0.627]
NV	741	3/2	+0.125	[−0.376, 0.627]
H	741	3/2	+0.125	[−0.376, 0.627]

V 的两次修复有明确错误求和或乘法支持，但仅两个得分分歧，精确双侧配对符号检验 p=.5。另一题改选算术更一致的复利答案，仍违背按原本金计息条件。局部校正没有新增候选间消息传递，不能把这两题计作新交互结构的收益。

关系探针在训练内开发 48 题，冻结后检查 106 道去重题及 107 条判断。单位、实体、条件、目标四族均未达到预设覆盖与忠实性门槛，没有训练关系选择模型。字面复述不等于使用条件，单位相同不等于语义角色相同。[13] 当前可核实证据仍不足以解决主要题意绑定问题。

8 冻结测试与资源结果

8.1 最终评价与数据筛选差异

10 月 28 日，V 及其他五套比较方案的代码、权重、配置、顺序和主候选身份在评分前冻结。六份预测全部生成并保存哈希后，再逐一独立评分；未按测试结果重训、融合或更改主候选。[14]

表 11　评分前冻结的六套方案

方案	全验证/798	多答案验证/355	测试/467	测试准确率
V 仅矛盾 主候选	742	299	374	80.086%
H 历史算术	741	298	377	80.728%
NV 数量加矛盾	741	298	377	80.728%
B S2-C 五成员	740	297	368	78.801%
S2_route 固定回退	740	297	383	82.013%
Pool-P 五成员	736	293	375	80.300%

V 是测试前选择的主候选，S2_route 是六套方案中的测试观察最高者。后者来自普通 S2，而 B 来自 S2-C；二者差值不能单独归因于回退或“晚期交换”。测试也没有包含初始独立/Pool/A 及完整阶段对照，不能作为所有机制结论的独立确认。

六方案均选对 443 道单有效答案组验证题，故完整验证准确率与 355 题分歧准确率是线性换算，不是两份独立证据。S2_route 从完整验证 92.732%到测试 82.013%相差 10.719 个百分点；按多答案筛选比较则为 83.662%到 82.013%，相差 1.649。V 对应 84.225%到 80.086%，相差 4.140 个百分点。容易题比例解释分数尺度，却不改变六方案验证排名，不能单独解释测试排名翻转；其余差异可能涉及抽样、内部难度构成和反复开发偏差，现有证据不能分离。

8.2 计算与资产

表 12　完整 467 题的新预测进程加独立评分进程

方案	本机墙钟秒	展开后推理资产 MiB
V	7.642	5.24880
H	9.513	5.24892
NV	8.788	5.24887
B	5.289	5.24866
S2_route	5.442	5.24164
Pool-P	5.353	2.87068

本机为 AMD Ryzen 7 4800U，Python3.12.14、NumPy2.5.3、PyTorch2.7.1+cpu。数值任务串行，Torch intra-op4、inter-op1，OpenBLAS1。时间包括启动、导入、数据和资产加载、预处理及所有成员；资产按 NPZ 展开内容计数，含权重、统计与配置。六套分别低于 16MiB，但本机测时不等于官方 Xeon 四线程 30 秒认证，单次计时也不构成精确速度排名。

9 讨论与研究结论

9.1 对四个主线问题的回答

是否交换。 初始表示层上下文读取有明确开发集支持；近容量和仅自身控制排除了部分替代解释。但混合题训练缩小了结构差距，说明交互收益依赖监督和训练分配，不能无条件推广。

交换什么。 固定向量上下文与显式答案共识产生不同效果。后者明显改变了少数正确答案的选择，支持谨慎使用群体统计；现有实验尚未定位注意力实际读取的语义信息，也没有证明模型理解了候选间的条件冲突。

怎样交换。 简单均值汇总已是强基线。更多头、更复杂组表示或专家选择没有稳定兑现额外收益；oracle 上界与可部署方法之间仍有差距。负结果界定了当前预算下的方法边界，而不是证明所有同类结构无效。

何时交换。 S2 的非线性加工与归一化顺序提供了待确认信号，早注入共识及两阶段残差没有形成可靠优势。三者改变的路径和优化条件不同，现有证据不能确定统一最佳时机。

9.2 局限与后续研究

验证集被反复用于结构、协议与特征开发；五种子和配对区间不能消除适应性选择偏差。OOF 基础预测对基础模型留出，但在全 OOF 上拟合的校正器仍需独立评价。人工错误分类与关系审计没有第二位独立评审。固定数值标签不衡量全程推理正确性，且错误子组相互重叠，均限制解释范围。

后续更有信息价值的比较，是在相同参数化下区分固定均匀读取与学习式读取，以及区分共识仅作用于 Q/K、V 或评分头的路径。若引入局部条件证据，应先验证提取忠实性和可区分覆盖，再检查它通过跨候选通路带来的增量。上述方向尚未执行；需要新的开发与确认安排，不能在已见测试错因上继续修改后仍称为独立测试。

10 复现与研究投入

累计 577 次神经网络拟合包括重复基线、学习率搜索和折内训练，并非 577 个独立结构。各组次数依次为初始 48、目标 48、容量 60、残差 42、头数 48、阶段 36、融合 140、重加权 30、结构×共识 30、早注入 40、互补 25、答案组 30。文本和算术另各 3 次线性残差拟合；阈值、权重及门控搜索另计。计时范围不同，不将各组耗时直接相加为纯训练时间。

研究代码版本为 ae19325，最终六方案的确切资产和命令见 final_test_20261028/frozen_before_test.json；相应文件哈希用于对应权重。V 的入口为 arith_relation_audit_20261018/portable/inference/method.py，checkpoint 为同 portable 下的 pipelines/V。从 code 目录安装上述依赖并限制线程后，用 predict.py 指定该入口、checkpoint、split 及新输出路径；再用 score_predictions.py 独立评分。预期验证 742/798，测试 374/467，测试 accuracy=80.08565310492506。详细环境与命令见配套复现说明及各组 README。[14]

实验设计、代码、运行编排、文本审阅和写作使用 Codex AI 辅助。训练仅用给定训练输入与标签，无外部数据或额外预训练权重。题目源于 GSM8K，候选和表示由课程 Qwen3-0.6B 提供，归属与许可沿用数据文件。[1]

实验来源与复现索引

下列路径均相对仓库 code 目录，除特别注明外，主记录为对应目录的 results/REPORT.md。编号用于连接研究结论与原始实验，不代表独立数据集或精确执行时间顺序。各组保留配置、种子、官方评分、配对统计、资源记录及复现入口。

[1] 课程任务与固定评分协议。../guide/GUIDE.md；data/manifest.json；data/NOTICE.txt；code 根目录 README.md。任务目标、数据筛选及资源约束以官方说明为准。

[2] 初始结构与题目分支。experiments_20261017。包含线性、独立、Pool、注意力、近容量、仅自身与题目词袋对照，五种子及配对结果。

[3] 训练目标与容量控制。objective_experiments_20261017；capacity_experiments_20261017。包含全部/混合题、排序/集合目标、宽度与正则化，以及基线重放。

[4] 交换方式与网络阶段。residual_experiments_20261017；attention_factors_20261017；interaction_stage_20261017。包含两阶段修正、头数与 self mask，以及 S0—S5 顺序和固定轮次敏感性记录。

[5] 显式特征、集成与置信度。fusion_confidence_20261017。包含解析/共识/风格、五与十五成员、训练 OOF、校准及冻结回退。explicit_features.py 给出特征定义。

[6] 最终有效性约束。validity_filter_20261017。包含 19 对过滤前后比较、回退的统一过滤归因与修复/损害。

[7] 结构与共识的因子对照。interaction_consensus_20261017。包含 I/Pool/S2×P/C、匹配初始化、统一过滤和主要交互项。

[8] 训练分配与注入位置。reweighting_experiments_20261017；early_consensus_20261017。分别包含 U/K/H 权重控制及 All/D×P/C×Early/Late 实验。

[9] 答案组表示与支持数。answer_group_20261018。包含 CandBCE/CandMaxCE/GroupCE×NoSize/Size、匹配读出及组概率集成。

[10] 方法互补与专家选择。method_complementarity_20261017。包含 Pool-P/S2-C 分歧、训练 OOF 权重、gate8/gate4、oracle 与冻结验证结果。

[11] 共同错误审阅。common_failure_diagnosis_20261017。42 题诊断与必要全文证据见主报告和 case_reviews.csv。早期自动索引另见 error_diagnosis_20261017/REPORT.md，其三代表共同错 38 题是不同集合。

[12] 格式与局部算术。text_evidence_20261017。包含训练提取审计、v0/v1 修订快照、冻结校正及数量代理的事后解释。

[13] 数量与矛盾消融及关系可行性。arith_relation_audit_20261018。包含 B/N/V/NV/H、冻结训练内关系审阅、portable 推理包与 reproduce.py。该复现脚本复用主模型和 OOF，不等于从零训练基础网络。

[14] 冻结最终测试与复现。final_test_20261028/results/REPORT.md 及 frozen_before_test.json；各方案 results 下的 score.json。环境和命令另见 final_report_20261028/REPRODUCIBILITY.md，其历史“未全部提交”状态现由 ae19325 取代。

当前结论对应本课程候选生成方式、固定表示与计算约束。上述记录保留未提升和未进入建模的结果，供复核比较是否匹配、收益是否净增及解释是否超出证据。